

# GÉNÉRATION DE VISAGES PHOTO- RÉALISTES

AVEC CONTRÔLE D'ATTRIBUTS DÉMOGRAPHIQUES

## **État de l'art**

*Techniques de génération, contrôle conditionnel et métriques d'évaluation*

Travail réalisé par

Edouard LOUAMOU · Isaac KOUMOUS · Jeffrey TANDJEU · Kelian SUAMI

Projet MSC AIC, IA Générative

## Sommaire

|                                                                        |    |
|------------------------------------------------------------------------|----|
| Sommaire .....                                                         | 2  |
| 1. Introduction et problématique .....                                 | 3  |
| 2. Techniques de génération de visages .....                           | 3  |
| 2.1 Auto-encodeurs variationnels (VAE) .....                           | 3  |
| 2.2 Réseaux antagonistes génératifs (GANs) .....                       | 4  |
| 2.3 Modèles de diffusion .....                                         | 4  |
| 2.4 Synthèse comparative .....                                         | 5  |
| 3. Méthodes de contrôle conditionnel.....                              | 6  |
| 3.1 Conditionnement par classe (class conditioning) .....              | 6  |
| 3.2 Guidage : classifier guidance et classifier-free guidance .....    | 6  |
| 3.3 Désintrication de caractéristiques (feature disentanglement) ..... | 7  |
| 3.4 Encodage des attributs : classes discrètes et âge continu .....    | 7  |
| 4. Métriques d'évaluation .....                                        | 7  |
| 4.1 Fréchet Inception Distance (FID) .....                             | 7  |
| 4.2 Inception Score (IS).....                                          | 8  |
| 4.3 LPIPS : distance perceptuelle et mesure de diversité .....         | 8  |
| 4.4 Fidélité aux attributs .....                                       | 8  |
| 5. Jeux de données .....                                               | 8  |
| 6. Positionnement et justification de notre approche .....             | 9  |
| 7. Considérations éthiques .....                                       | 10 |
| 7.1 Biais des données et représentativité .....                        | 10 |
| 7.2 Implications sociétales et mésusages .....                         | 10 |
| 7.3 Données personnelles .....                                         | 10 |
| 8. Conclusion .....                                                    | 10 |
| Références .....                                                       | 12 |

## 1. Introduction et problématique

La génération d'images de visages humains photo-réalistes constitue depuis une décennie l'un des bancs d'essai les plus exigeants de l'intelligence artificielle générative. Le visage humain est un objet visuel singulier : sa structure est fortement contrainte (symétrie, position des traits), mais notre système perceptif y est extraordinairement sensible, de sorte que la moindre incohérence anatomique est immédiatement détectée, phénomène connu sous le nom de « vallée de l'étrange ». Réussir à générer des visages convaincants exige donc des modèles capables de capturer à la fois la structure globale et les micro-textures (grain de peau, cheveux, reflets oculaires).

Au-delà du réalisme, ce projet pose une seconde exigence, plus difficile encore : le contrôle. Il ne s'agit pas seulement d'échantillonner des visages plausibles, mais de générer un visage possédant des attributs démographiques précis, un âge dans la plage 18-70 ans (idéalement contrôlé de manière continue), un genre, et une couleur de peau parmi un ensemble représentatif de la diversité humaine. Ce cahier des charges déplace le problème de la génération inconditionnelle  $p(x)$  vers la génération conditionnelle  $p(x|c)$ , où  $c$  est un vecteur d'attributs, et soulève trois questions scientifiques que cet état de l'art examine successivement :

- Quelle famille de modèles génératifs offre aujourd'hui le meilleur compromis entre réalisme, stabilité d'entraînement et aptitude au conditionnement ? (section 2)
- Comment injecter et faire respecter la condition : encodage des attributs, mécanismes de guidage, désintrication des facteurs de variation ? (section 3)
- Comment évaluer objectivement le réalisme, la diversité et la fidélité aux attributs des visages générés ? (section 4)

Les sections 5 et 6 complètent l'analyse par une revue des jeux de données annotés en attributs démographiques et par la justification argumentée de notre choix architectural. La section 7 traite des considérations éthiques, indissociables d'un système générant des visages synthétiques contrôlés par des attributs démographiques.

## 2. Techniques de génération de visages

Un modèle génératif apprend la distribution de probabilité sous-jacente  $p(x)$  d'un ensemble de données, afin d'en échantillonner de nouvelles instances. Quatre grandes familles ont marqué la génération de visages : les auto-encodeurs variationnels, les réseaux antagonistes génératifs, les modèles autorégressifs et les modèles de diffusion. Nous concentrons l'analyse sur les deux familles dominantes pour les visages (GANs et diffusion) après un bref passage par les VAE dont les concepts (espace latent, encodeur/décodeur) irriguent toutes les autres approches.

### 2.1 Auto-encodeurs variationnels (VAE)

Le VAE [2] apprend simultanément un encodeur  $q(z|x)$ , qui projette l'image dans un espace latent de faible dimension, et un décodeur  $p(x|z)$ , qui la reconstruit. L'entraînement maximise une borne inférieure de la vraisemblance (ELBO) combinant une erreur de reconstruction et une régularisation KL qui contraint l'espace latent à suivre une gaussienne standard, ce qui permet ensuite d'échantillonner  $z$

$\sim N(0, I)$  et de décoder de nouveaux visages. Les VAE sont stables à entraîner et offrent un espace latent naturellement structuré, propice à l'interpolation. Leur défaut historique est le flou des images générées : la vraisemblance gaussienne pénalise mal les hautes fréquences, et le modèle « moyenne » les détails. Ils survivent aujourd'hui surtout comme composants : le VQ-VAE et le VAE de compression de Stable Diffusion [15] en sont les héritiers directs.

## 2.2 Réseaux antagonistes génératifs (GANs)

### 2.2.1 Le cadre adversaire et DCGAN

Le GAN [1] formule la génération comme un jeu à deux joueurs : un générateur  $G$  transforme un bruit  $z$  en image, un discriminateur  $D$  apprend à distinguer images réelles et générées, et  $G$  est entraîné à tromper  $D$ . À l'équilibre théorique, la distribution de  $G$  coïncide avec celle des données. Contrairement au VAE, aucune vraisemblance n'est calculée : la « fonction de perte » est apprise par  $D$ , ce qui produit des images nettes. Le prix à payer est une optimisation minimax notoirement instable : effondrement des modes (mode collapse), oscillations, gradients évanescents [27]. DCGAN [3] a établi les règles architecturales rendant l'entraînement praticable sur des images : convolutions transposées à pas fractionnaire pour l'agrandissement, batch normalization, activations ReLU/LeakyReLU, suppression des couches denses. C'est l'architecture étudiée dans notre cours et le socle de notre baseline conditionnelle.

### 2.2.2 Progressive GAN : la montée en résolution

ProGAN [6] a débloqué la haute résolution (1024×1024 sur CelebA-HQ) par croissance progressive : l'entraînement démarre à 4×4 puis ajoute des couches de résolution croissante, chaque étape affinant un problème déjà partiellement résolu. S'y ajoutent la minibatch standard deviation (statistique de diversité fournie à  $D$  pour combattre le mode collapse) et l'égalisation du taux d'apprentissage. ProGAN a prouvé que les GANs pouvaient produire des visages haute fidélité, tout en restant un générateur « boîte noire » sans contrôle sémantique.

### 2.2.3 La famille StyleGAN : vers un espace latent contrôlable

StyleGAN [7] réorganise le générateur autour de la notion de style : le code latent  $z$  est d'abord transformé par un réseau de mapping en un vecteur  $w \in W$ , injecté à chaque résolution via une normalisation adaptative (AdaIN), tandis que du bruit par pixel fournit la stochasticité fine (mèches de cheveux, pores). Cette séparation styles/bruit produit un espace  $W$  remarquablement désintriqué : les directions de  $W$  correspondent à des facteurs sémantiques (pose, âge, lunettes), propriété fondatrice pour le contrôle d'attributs (section 3.3). StyleGAN2 [8] corrige les artefacts « gouttes d'eau » en remplaçant AdaIN par une modulation/démodulation des poids, et introduit la régularisation de longueur de chemin ; StyleGAN3 [9] élimine l'aliasing pour rendre le générateur équivariant aux translations. Sur FFHQ, StyleGAN2 atteint un FID d'environ 3, longtemps l'état de l'art absolu du photo-réalisme facial.

## 2.3 Modèles de diffusion

### 2.3.1 DDPM : principe et formulation

Les modèles de diffusion [10] reposent sur une asymétrie simple : détruire une image par bruitage progressif est trivial ; apprendre à inverser cette destruction pas à pas est faisable et stable. Le processus forward ajoute du bruit gaussien sur  $T$  étapes selon un programme de variance  $\beta_t$  :

$$q(x_t / x_{t-1}) = N(x_t ; \sqrt{(1-\beta_t)} \cdot x_{t-1}, \beta_t \cdot I)$$

Grâce à la propriété de composition des gaussiennes,  $x_t$  s'échantillonne directement depuis  $x_0$  :  $x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1-\bar{\alpha}_t} \varepsilon$  avec  $\varepsilon \sim N(0, I)$ . Le réseau (un UNet conditionné par l'étape  $t$ ) apprend à prédire le bruit  $\varepsilon$  ajouté, en minimisant une simple erreur quadratique :

$$L = E[\|\varepsilon - \varepsilon\theta(x_t, t)\|^2]$$

À l'inférence, on part d'un bruit pur  $x_T$  et on débruite itérativement. Cette perte de régression, sans dynamique adversaire, explique la stabilité remarquable de l'entraînement : pas de mode collapse, convergence monotone, hyperparamètres peu sensibles. Improved DDPM [11] apporte le programme de bruit en cosinus (qui détruit l'information plus graduellement que le programme linéaire, bénéfique en basse résolution) et l'apprentissage des variances ; Dhariwal & Nichol [12] démontrent, avec une architecture UNet optimisée et le guidage par classifieur, que la diffusion surpasse les GANs en qualité d'image sur ImageNet, résultat charnière qui a fait basculer le domaine.

### 2.3.2 DDIM : échantillonnage rapide

Le talon d'Achille de la diffusion est le coût d'échantillonnage :  $T = 1000$  passages du réseau par image. DDIM [14] redéfinit le processus inverse comme non-markovien et déterministe (paramètre  $\eta = 0$ ), autorisant des sauts entre étapes : 20 à 50 pas suffisent pour une qualité proche du DDPM complet, soit un gain de 20 à 50x. Le déterminisme a une conséquence précieuse pour notre projet : à bruit initial  $x_T$  fixé, l'image générée est une fonction continue de la condition, ce qui rend l'interpolation d'attributs propre et reproductible, l'« identité » du visage étant portée par  $x_T$ .

### 2.3.3 Diffusion latente et Stable Diffusion

Les Latent Diffusion Models [15] déplacent la diffusion de l'espace pixel vers l'espace latent compressé d'un VAE (facteur 8 : une image 512×512 devient un tenseur 64×64×4), réduisant le coût d'un à deux ordres de grandeur. Le conditionnement (texte via CLIP, classes, images) est injecté par cross-attention dans l'UNet. Stable Diffusion en est l'incarnation publique, étudiée dans notre cours : son fine-tuning sur des visages est une piste valable, mais le pré-entraînement sur des milliards d'images introduit des biais incontrôlés et masque la compréhension des mécanismes, deux raisons de notre choix d'un entraînement from scratch (section 6).

## 2.4 Synthèse comparative

| Critère                          | VAE          | GAN (StyleGAN2)         | Diffusion (DDPM)        |
|----------------------------------|--------------|-------------------------|-------------------------|
| Réalisme                         | Moyen (flou) | Excellent               | Excellent               |
| Stabilité d'entraînement         | Excellente   | Faible (adversaire)     | Excellente (régression) |
| Couverture des modes / diversité | Bonne        | Risque de mode collapse | Très bonne              |
| Vitesse d'échantillonnage        | 1 passage    | 1 passage               | 20-1000 passages        |

| Critère                        | VAE    | GAN (StyleGAN2)          | Diffusion (DDPM) |
|--------------------------------|--------|--------------------------|------------------|
| Aptitude au conditionnement    | Bonne  | Bonne (complexe)         | Excellente (CFG) |
| Coût d'implémentation correcte | Faible | Élevé (astuces requises) | Modéré           |

En résumé : les GANs gardent l'avantage de l'inférence en un passage et d'un espace latent sémantique ; la diffusion offre la stabilité, la diversité et un mécanisme de conditionnement principal (classifier-free guidance) devenu le standard de l'industrie. C'est ce dernier point qui est décisif pour un projet centré sur le contrôle d'attributs.

### 3. Méthodes de contrôle conditionnel

Générer « un visage » ne suffit pas ; il faut générer « le visage demandé ». Deux paradigmes structurent la littérature : le conditionnement par classe (la condition est fournie au modèle pendant l'entraînement) et la désintrication de caractéristiques (on découvre a posteriori, dans l'espace latent d'un modèle inconditionnel, les directions qui contrôlent chaque attribut).

#### 3.1 Conditionnement par classe (class conditioning)

Le cGAN [4] initie le paradigme : l'étiquette  $c$  est concaténée à l'entrée du générateur et du discriminateur, qui apprennent ainsi  $p(x|c)$ . AC-GAN [5] renforce le signal en ajoutant à  $D$  une tête auxiliaire de classification qui doit retrouver  $c$  depuis l'image, la fidélité à la condition devient un objectif explicite. Le discriminateur à projection [26] remplace la concaténation par un produit scalaire entre l'embedding de la condition et les caractéristiques de l'image dans  $D$ , formulation dérivée du modèle probabiliste sous-jacent et sensiblement plus stable ; c'est la variante retenue pour notre baseline. Côté diffusion, le conditionnement est architecturalement plus simple : l'embedding de la condition est ajouté à l'embedding temporel injecté dans chaque bloc résiduel de l'UNet (ou par cross-attention pour des conditions riches comme le texte). Le réseau apprend  $\epsilon(x_t, t, c)$  et le conditionnement traverse naturellement tout le processus de débruitage.

#### 3.2 Guidage : classifier guidance et classifier-free guidance

Conditionner ne garantit pas que la condition soit respectée : le modèle peut apprendre à l'ignorer partiellement. Le guidage par classifieur [12] corrige la trajectoire de débruitage avec le gradient  $\nabla \log p(c|x_t)$  d'un classifieur entraîné sur images bruitées, efficace mais coûteux (un second réseau) et fragile. Le classifier-free guidance (CFG) [13] élimine ce classifieur par une idée élégante : entraîner un seul réseau en mode conditionnel et inconditionnel (la condition est aléatoirement masquée avec une probabilité d'environ 10 %), puis, à l'échantillonnage, extrapoler entre les deux prédictions :

$$\hat{\epsilon} = \epsilon(x_t, \emptyset) + w \cdot (\epsilon(x_t, c) - \epsilon(x_t, \emptyset))$$

Le scalaire  $w$  règle continûment le compromis fidélité/diversité :  $w = 1$  restitue l'échantillonnage conditionnel simple ;  $w > 1$  amplifie la direction « ce qui distingue la condition », augmentant l'adhérence aux attributs au prix d'une diversité et parfois d'un naturel moindres. Ce bouton de contrôle unique,

sans réseau supplémentaire, explique l'adoption universelle du CFG (Stable Diffusion, DALL-E, Imagen) et en fait l'outil idéal pour notre cahier des charges : nous l'exposons directement dans l'interface utilisateur.

### 3.3 Désintrication de caractéristiques (feature disentanglement)

L'approche duale exploite un générateur inconditionnel déjà entraîné. InfoGAN [16] force, dès l'entraînement, un sous-ensemble du code latent à être informatif (maximisation d'information mutuelle), faisant émerger des facteurs interprétables sans supervision. Avec StyleGAN, la désintrication devient exploitable a posteriori : InterFaceGAN [17] entraîne un simple SVM dans l'espace latent pour séparer, par exemple, les visages jeunes des visages âgés (la normale de l'hyperplan est alors une direction d'édition de l'âge) ; GANSpace [18] découvre des directions par simple ACP des latents. Ces méthodes produisent des éditions visuellement convaincantes mais souffrent de l'intrication résiduelle : la direction « âge » modifie souvent lunettes ou expression, et le contrôle précis d'attributs multiples exige des orthogonalisations délicates. Pour un contrôle démographique exact, objet du projet, le conditionnement explicite pendant l'entraînement reste plus fiable ; la désintrication demeure en revanche la référence pour l'édition de visages réels existants.

### 3.4 Encodage des attributs : classes discrètes et âge continu

Le sujet impose un âge contrôlable « par tranches ou de manière continue » sur 18-70 ans. Traiter l'âge en classes discrètes (tranches de 10 ans) simplifie l'apprentissage mais interdit la génération à âge arbitraire et crée des discontinuités aux frontières. Nous encodons donc l'âge comme un scalaire normalisé dans  $[0, 1]$ , transformé par un embedding sinusoïdal (le même mécanisme qui encode l'étape de diffusion  $t$ ) puis un MLP, représentation lisse qui autorise l'interpolation continue « le même visage à 25, 40, 60 ans ». Genre et groupe de peau, intrinsèquement catégoriels, passent par des tables d'embeddings apprises. Les trois vecteurs sont sommés avec l'embedding temporel, et chaque attribut possède un embedding « nul » appris pour le masquage du CFG.

## 4. Métriques d'évaluation

L'évaluation des modèles génératifs est un problème en soi : il n'existe pas de vérité terrain par image générée. La pratique combine des métriques de réalisme distributionnel, de diversité, et (spécificité de notre projet) de fidélité aux attributs demandés.

### 4.1 Fréchet Inception Distance (FID)

Le FID [19] est la métrique de référence. Images réelles et générées sont plongées dans l'espace de caractéristiques d'un réseau Inception-v3 pré-entraîné ; chaque ensemble est résumé par une gaussienne  $(\mu, \Sigma)$ , et le FID est la distance de Fréchet entre les deux :

$$FID = \|\mu_r - \mu_g\|^2 + \text{Tr}(\Sigma_r + \Sigma_g - 2(\Sigma_r \Sigma_g)^{1/2})$$

Plus il est bas, plus les distributions se ressemblent, en réalisme et en diversité simultanément (un modèle en mode collapse a un mauvais FID même avec de belles images). Limites connues : biais au nombre d'échantillons (50 000 recommandés, à nombre fixe pour comparer), sensibilité au

prétraitement (redimensionnement, compression JPEG), et dépendance aux caractéristiques Inception entraînées sur ImageNet, peu spécifiques des visages. Ordres de grandeur sur visages :  $\sim 3$  pour StyleGAN2/FFHQ à haute résolution ; pour un DDPM  $64 \times 64$  entraîné from scratch avec des moyens étudiants, un FID de 15 à 30 est un objectif réaliste.

## 4.2 Inception Score (IS)

L'IS [20] mesure, sans référence aux données réelles, deux souhaits simultanés : chaque image doit être reconnaissable ( $p(y|x)$  piquée) et l'ensemble doit être varié ( $p(y)$  uniforme), formellement l'exponentielle de la divergence KL moyenne entre les deux. Pertinent sur ImageNet, il est peu discriminant sur les visages : toutes les images appartiennent à la même classe Inception (« visage »), et un IS élevé y est vite atteint. Nous le rapportons par convention et complétude, le FID restant la métrique principale.

## 4.3 LPIPS : distance perceptuelle et mesure de diversité

LPIPS [21] mesure la distance entre deux images dans l'espace des activations d'un réseau profond, calibré sur des jugements humains (bien plus fidèle à la perception que le PSNR ou le SSIM). Au-delà de son usage en similarité, nous l'employons comme mesure de diversité intra-condition : pour des attributs fixés, on génère  $N$  visages et on calcule le LPIPS moyen entre paires. Une valeur élevée indique que le modèle produit des identités variées pour une même condition ; une valeur proche de zéro trahit un mode collapse conditionnel, pathologie typique des cGANs que cette métrique rend visible et que la comparaison DDPM/cGAN de notre démonstrateur illustre. Precision/Recall pour modèles génératifs [22] complète ce tableau en séparant explicitement réalisme (precision) et couverture (recall).

## 4.4 Fidélité aux attributs

Aucune métrique standard ne mesure « le visage a-t-il bien l'âge demandé ? ». La pratique consensuelle consiste à entraîner un classifieur d'attributs indépendant (dans notre cas un ResNet-18 à trois têtes : régression d'âge, genre, groupe de peau, entraîné sur FairFace) et à confronter ses prédictions sur les visages générés aux attributs demandés. Nous rapportons l'exactitude pour genre et peau, et l'erreur absolue moyenne en années pour l'âge, ainsi que leur évolution en fonction du poids de guidage  $w$ , courbe qui matérialise expérimentalement le compromis fidélité/diversité du CFG. Cette évaluation a ses limites, discutées en section 7 : le classifieur a ses propres biais, qui peuvent différer selon les groupes démographiques [28].

# 5. Jeux de données

| Dataset       | Taille          | Annotations                                  | Atouts / limites pour ce projet                                                                                     |
|---------------|-----------------|----------------------------------------------|---------------------------------------------------------------------------------------------------------------------|
| FairFace [23] | $\sim 108\,000$ | âge (9 tranches), genre, 7 groupes ethniques | Équilibré démographiquement (conçu contre les biais) ; résolution modérée ( $\sim 224\text{px}$ ). Choix principal. |
| UTKFace [24]  | $\sim 20\,000$  | âge exact (années), genre, 5 ethnies         | Âge continu idéal pour la régression ; plus petit, qualité variable. Complément/alternative.                        |



| Dataset        | Taille | Annotations                             | Atouts / limites pour ce projet                                                |
|----------------|--------|-----------------------------------------|--------------------------------------------------------------------------------|
| CelebA-HQ [25] | 30 000 | 40 attributs binaires                   | Haute résolution (1024px) ; pas d'âge numérique ni d'ethnie, biais célébrités. |
| FFHQ [7]       | 70 000 | aucune (âge/genre estimés a posteriori) | Référence qualité/diversité pour StyleGAN ; non annoté pour nos attributs.     |

FairFace s'impose pour ce projet : c'est le seul corpus à la fois annoté sur nos trois attributs exacts et construit explicitement pour l'équilibre des groupes démographiques, les sept groupes  $y$  sont représentés à parts quasi égales, là où CelebA ou FFHQ sur-représentent massivement certains phénotypes. Cet équilibre conditionne directement la capacité du modèle à générer avec une qualité homogène toutes les combinaisons d'attributs (section 7). L'annotation d'âge par tranches est convertie en valeur continue (milieu de tranche), et la plage est filtrée à 18-70 ans conformément au sujet ; UTKFace, annoté à l'année près, sert de complément pour valider le contrôle continu de l'âge.

## 6. Positionnement et justification de notre approche

Au terme de cette revue, notre système retient : un DDPM conditionnel entraîné from scratch sur FairFace à 64×64 (extensible à 128), avec programme de bruit en cosinus [11], conditionnement par embeddings sommés (âge continu sinusoïdal, genre et peau catégoriels), classifier-free guidance [13] pour le contrôle, échantillonnage DDIM à 50 pas [14] pour la quasi-temps-réalité, et EMA des poids. Un cGAN à discriminateur à projection [26], partageant le même encodage d'attributs, sert de méthode de référence. Ce choix s'appuie sur quatre arguments :

- **Adéquation au besoin de contrôle** : le CFG offre un mécanisme de conditionnement principal avec un réglage continu de la fidélité, exactement la fonctionnalité centrale demandée ; les alternatives GAN exigent des astuces (têtes auxiliaires, orthogonalisation de directions latentes) moins fiables sur trois attributs simultanés.
- **Stabilité et reproductibilité** : la perte de régression du DDPM converge de façon monotone, sans l'instabilité adverse, critère décisif avec un budget GPU étudiant, où chaque relance d'entraînement coûte des heures.
- **Cohérence pédagogique** : l'approche prolonge directement les notions du cours (DCGAN pour la baseline, boucle de diffusion, scheduler, CFG vus en TP Stable Diffusion), et l'entraînement from scratch démontre la compréhension des mécanismes là où un fine-tuning de Stable Diffusion hériterait de biais et de capacités non maîtrisés.
- **Comparaison scientifique équitable** : DDPM et cGAN partagent dataset, résolution, encodage d'attributs et protocole d'évaluation (FID, IS, LPIPS intra-condition, fidélité par classifieur), isolant proprement la variable « famille de modèle ».

Les limites assumées : la résolution modérée (64-128px contre 1024px pour StyleGAN2, le coût d'entraînement de la haute résolution étant hors de portée du projet), et un coût d'inférence supérieur au GAN, ramené à 1-3 secondes par lot grâce à DDIM, compatible avec l'exigence de quasi-temps-réel de l'interface.

## 7. Considérations éthiques

### 7.1 Biais des données et représentativité

Tout modèle génératif hérite des biais de son corpus. Les datasets historiques de visages sont déséquilibrés : CelebA sur-représente des célébrités jeunes à peau claire ; les conséquences documentées de tels déséquilibres vont de la qualité de génération dégradée pour les groupes minoritaires aux erreurs de classification discriminatoires [28]. Notre choix de FairFace comme corpus principal est une décision éthique autant que technique. Nous évaluons en outre la qualité (FID) et la fidélité par groupe démographique, et non seulement en moyenne globale, une moyenne flatteuse pouvant masquer un effondrement sur un groupe minoritaire. Les catégories elles-mêmes appellent la prudence : sept groupes discrets ne sauraient épuiser la diversité humaine, et « genre » y est réduit à un binaire hérité des annotations disponibles ; nous le documentons comme une limite du cadre, non comme une position.'

### 7.2 Implications sociétales et mésusages

Un générateur de visages contrôlable a des usages légitimes (données synthétiques respectueuses de la vie privée, anonymisation, création artistique, équilibrage de datasets) et des mésusages sérieux : deepfakes, faux profils, usurpation. Plusieurs propriétés de notre démonstrateur limitent structurellement les risques : les visages sont générés à basse résolution depuis du bruit, le système ne peut ni cibler ni reproduire une personne réelle, n'ayant aucune fonction d'inversion ou d'édition d'images existantes. Nous y ajoutons des mesures de bonne pratique : mention explicite « visage synthétique » dans l'interface, documentation des usages proscrits, et non-diffusion des poids hors du cadre pédagogique. À l'échelle du domaine, la réponse passe par le watermarking des contenus générés (norme C2PA), les détecteurs de synthèse, et les cadres réglementaires de type AI Act européen, qui impose la transparence sur les contenus synthétiques.

### 7.3 Données personnelles

Les visages d'entraînement sont des données biométriques de personnes n'ayant généralement pas consenti à cet usage, problème générique des corpus collectés sur le web, que FairFace (images sous licence Creative Commons, usage recherche) atténue sans l'éliminer. Le projet reste dans un cadre strictement pédagogique : pas de redistribution des données, pas de tentative de ré-identification, et les visages générés, purement synthétiques, ne correspondent à aucune personne existante.

## 8. Conclusion

Cet état de l'art a retracé la trajectoire de la génération de visages : des VAE fondateurs mais flous, aux GANs qui ont conquis le photo-réalisme (DCGAN, ProGAN, StyleGAN) au prix d'une instabilité chronique, jusqu'aux modèles de diffusion qui dominent depuis 2021 en combinant qualité, stabilité et (via le classifieur-free guidance) le mécanisme de contrôle conditionnel le plus propre du domaine. Pour le contrôle d'attributs démographiques précis, la littérature oriente clairement vers le conditionnement explicite à l'entraînement plutôt que la désintrication a posteriori, et vers une évaluation à trois volets : réalisme distributionnel (FID), diversité intra-condition (LPIPS), fidélité aux attributs (classifieur

indépendant). Notre système (DDPM conditionnel + CFG sur FairFace, confronté à une baseline cGAN à protocole égal) opérationnalise ces conclusions, avec une attention explicite aux biais démographiques et aux mésusages. Le démonstrateur qui l'accompagne permet d'en éprouver interactivement les capacités : génération aux attributs choisis, âge continu, interpolation d'identité fixe, et comparaison directe des deux familles de modèles.

## Références

- [1] Goodfellow, I. et al. (2014). Generative Adversarial Nets. NeurIPS.
- [2] Kingma, D. P., & Welling, M. (2014). Auto-Encoding Variational Bayes. ICLR.
- [3] Radford, A., Metz, L., & Chintala, S. (2016). Unsupervised Representation Learning with Deep Convolutional GANs (DCGAN). ICLR.
- [4] Mirza, M., & Osindero, S. (2014). Conditional Generative Adversarial Nets. arXiv:1411.1784.
- [5] Odena, A., Olah, C., & Shlens, J. (2017). Conditional Image Synthesis with Auxiliary Classifier GANs (AC-GAN). ICML.
- [6] Karras, T. et al. (2018). Progressive Growing of GANs for Improved Quality, Stability, and Variation. ICLR.
- [7] Karras, T., Laine, S., & Aila, T. (2019). A Style-Based Generator Architecture for GANs (StyleGAN). CVPR.
- [8] Karras, T. et al. (2020). Analyzing and Improving the Image Quality of StyleGAN (StyleGAN2). CVPR.
- [9] Karras, T. et al. (2021). Alias-Free Generative Adversarial Networks (StyleGAN3). NeurIPS.
- [10] Ho, J., Jain, A., & Abbeel, P. (2020). Denoising Diffusion Probabilistic Models. NeurIPS.
- [11] Nichol, A., & Dhariwal, P. (2021). Improved Denoising Diffusion Probabilistic Models. ICML.
- [12] Dhariwal, P., & Nichol, A. (2021). Diffusion Models Beat GANs on Image Synthesis. NeurIPS.
- [13] Ho, J., & Salimans, T. (2022). Classifier-Free Diffusion Guidance. arXiv:2207.12598.
- [14] Song, J., Meng, C., & Ermon, S. (2021). Denoising Diffusion Implicit Models (DDIM). ICLR.
- [15] Rombach, R. et al. (2022). High-Resolution Image Synthesis with Latent Diffusion Models (Stable Diffusion). CVPR.
- [16] Chen, X. et al. (2016). InfoGAN: Interpretable Representation Learning by Information Maximizing GAN. NeurIPS.
- [17] Shen, Y. et al. (2020). Interpreting the Latent Space of GANs for Semantic Face Editing (InterFaceGAN). CVPR.
- [18] Härkönen, E. et al. (2020). GANSpace: Discovering Interpretable GAN Controls. NeurIPS.
- [19] Heusel, M. et al. (2017). GANs Trained by a Two Time-Scale Update Rule Converge to a Local Nash Equilibrium (FID). NeurIPS.
- [20] Salimans, T. et al. (2016). Improved Techniques for Training GANs (Inception Score). NeurIPS.
- [21] Zhang, R. et al. (2018). The Unreasonable Effectiveness of Deep Features as a Perceptual Metric (LPIPS). CVPR.
- [22] Kynkäänniemi, T. et al. (2019). Improved Precision and Recall Metric for Assessing Generative Models. NeurIPS.
- [23] Kärkkäinen, K., & Joo, J. (2021). FairFace: Face Attribute Dataset for Balanced Race, Gender, and Age. WACV.
- [24] Zhang, Z., Song, Y., & Qi, H. (2017). Age Progression/Regression by Conditional Adversarial Autoencoder (UTKFace). CVPR.
- [25] Karras, T. et al. (2018). CelebA-HQ, introduit dans Progressive Growing of GANs. ICLR.
- [26] Miyato, T., & Koyama, M. (2018). cGANs with Projection Discriminator. ICLR.
- [27] Mescheder, L., Geiger, A., & Nowozin, S. (2018). Which Training Methods for GANs do actually Converge? ICML.
- [28] Buolamwini, J., & Gebru, T. (2018). Gender Shades: Intersectional Accuracy Disparities in Commercial Gender Classification. FAccT.